





CLUSTERING WITH K-MEANS

ALICE SHIZUKA HUTAGAOL





DATASET

Dataset yang digunakan: Pima Indians Diabetes (768 baris, 9 kolom)







Tujuan:

- Membagi pasien ke dalam 2 kelompok berdasarkan karakteristik kesehatannya
- Ingin melihat apakah hasil cluster dapat mencerminkan kondisi Diabetes atau tidak
- Setelah clustering, dilakukan evaluasi terhadap label asli (Outcome) dan fitur-fitur lain untuk interpretasi lebih lanjut

Metode utama: K-Means Clustering



CLUSTERING PIMA INDIAN USING K-MEANS



MODEL EVALUATION & CONFUSION MATRIX

=== K-Means Clustering Evaluation ===

Akurasi : 67.45%

F1 Score : 0.5353

Precision : 0.5333

Recall : 0.5373


Adjusted Rand : 0.1137

Silhouette : 0.1960


Tebakan benar : 518

Tebakan salah : 250

Meskipun ini unsupervised, evaluasi dilakukan dengan membandingkan hasil cluster dengan label asli Outcome untuk mengetahui apakah cluster mendekati kenyataan klinis.





DISTRIBUSI CLUSTER VS LABEL ASLI










DISTRIBUSI CLUSTER HAMPIR MIRIP DENGAN DISTRIBUSI LABEL ASLI (DIABETES: 35% VS 34.9%). INI MENUNJUKKAN K-MEANS BISA MEMBENTUK CLUSTER YANG SECARA PROPORSI CUKUP MENCERMINKAN DATA ASLI.

VALIDASI JUMLAH CLUSTER




ELBOW METHOD MENUNJUKKAN K=2 ADALAH TITIK OPTIMAL (INERTIA MENURUN SIGNIFIKAN SAMPAI K=2).
SILHOUETTE SCORE TERTINGGI JUGA ADA DI K=2.
INI MENDUKUNG BAHWA MEMBAGI DATA MENJADI 2 CLUSTER ADALAH PILIHAN YANG MASUK AKAL.

**"APAKAH
CLUSTER
MEWAKILI
KONDISI
DIABETES?"**




VISUALISASI PCA: APAKAH CLUSTER SESUAI LABEL DIABETES?



MENUNJUKKAN BAHWA CLUSTERING TIDAK MEREPRESENTASIKAN OUTCOME (DIABETES ATAU TIDAK DIABETES)

PERBEDAAN RATA-RATA FITUR TIAP CLUSTER









- FITUR YANG PALING MEMBEDAKAN CLUSTER ADALAH:
- AGE, INSULIN, GLUCOSE, DAN BLOODPRESSURE
 - CLUSTER 1 PUNYA NILAI LEBIH TINGGI DI FITUR-FITUR TERSEBUT.
 - RINGKASAN JUGA MENUNJUKKAN CLUSTER 1 PUNYA PERSENTASE DIABETES LEBIH TINGGI (52.1%) DIBANDING CLUSTER 0 (26.2%).

```
=== Ringkasan Karakteristik Tiap Cluster ===
```

	Cluster	Pregnancies	Glucose	Insulin	Age	Outcome (Persentase Diabetes)
0	0	2	115.4	85.7	26.7	26.2
1	1	7	131.9	68.1	46.2	52.1

**"APAKAH
CLUSTER
BERHUBUNGAN
DENGAN
METABOLIC
SYNDROM?"**





DATASET

Dataset yang digunakan:

- Pima Indians Diabetes (768 baris, 9 kolom)
- Metabolic Syndrom (2401 baris, 15 kolom)




Terdapat dua dataset yang digunakan. Fokus analisis utama ada pada dataset PIMA. Dataset Metabolic digunakan untuk tambahan analisis.


KORELASI FITUR DATASET METABOLIC SYNDROM TERHADAP CLUSTER

FITUR YANG PALING BERKORELASI DENGAN HASIL CLUSTER ADALAH:

- BLOOD GLUCOSE (0.8)
- PCA_2 (0.52)
- BMI_1 (0.22)
- INI MENGUATKAN BAHWA VARIABEL SEPERTI GLUKOSA DAN BMI BERPERAN PENTING DALAM PEMBENTUKAN CLUSTER.



CLUSTER RISIKO VS METABOLIC SYNDROME & DIABETES



Clustering membagi data menjadi dua: High Risk (merah) dan Low Risk (biru).

- Cluster High Risk memiliki persentase diabetes (60%) dan Metabolic Syndrome (40%) yang lebih tinggi.
- Sebaliknya, Low Risk hanya 20% dan 30%.
- Ini menunjukkan bahwa clustering berhasil mengidentifikasi kelompok risiko tinggi berdasarkan pola data.

Classification Report:

	precision	recall	f1-score	support
0	0.979798	1.000000	0.989796	97.000000
1	1.000000	0.964912	0.982143	57.000000
accuracy	0.987013	0.987013	0.987013	0.987013
macro avg	0.989899	0.982456	0.985969	154.000000
weighted avg	0.987275	0.987013	0.986963	154.000000

	MetabolicSyndrome	Persentase Diabetes	Persentase MetabolicSyndrome	\
0	0.3	20.0	30.0	
1	0.4	60.0	40.0	



KESIMPULAN


- Clustering awal belum mencerminkan kondisi diabetes secara akurat
 - Setelah memperluas fitur (gabung dengan data Metabolic Syndrome), cluster berhasil membentuk kelompok risiko tinggi & rendah
 - **Cluster High Risk** memiliki persentase diabetes & metabolic syndrome lebih besar
 - Fitur paling berpengaruh: **Glucose, Insulin, Age, Blood Pressure**
 - Clustering dapat digunakan untuk deteksi awal pasien berisiko tinggi tanpa perlu label
 - **Potensi penggunaan:** screening awal di klinik, segmentasi pasien, atau strategi pencegahan penyakit kronis berbasis data
- 

KESIMPULAN BISNIS

Metode unsupervised seperti K-Means bisa jadi alat bantu untuk identifikasi risiko, walaupun tanpa label awal. Meskipun di awal kurang akurat, tapi saat fiturnya ditambah dari dataset Metabolic Syndrome, hasil clustering mulai menunjukkan pola High Risk dan Low Risk yang valid.

Ini bisa jadi sangat bermanfaat untuk dunia medis atau bisnis kesehatan, misalnya:

- Klinik bisa pakai model clustering ini untuk menyaring pasien yang perlu dicek lebih lanjut
- Segmentasi pasien berdasarkan risiko bisa bantu rumah sakit atau BPJS untuk menyusun program pencegahan
- Bisa digunakan juga dalam telemedicine, untuk otomatis mengenali pasien yang perlu intervensi cepat
- Jadi walaupun metodenya sederhana, tapi hasilnya bisa dipakai langsung dalam strategi pencegahan atau pengelolaan risiko kesehatan.



THANK YOU!

